

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 面向旅行商问题的深度强化多指针Transformer 方法研究

学	号	<u>1025040712</u>
姓	名	<u>李钱</u>
导	师	<u>吴鹏飞</u>
专业学位类别		<u>计算机科学与技术</u>
类	型	<u>学术学位硕士</u>
专业（领域）		<u>计算机技术</u>
论文提交日期		<u>2026 年 6 月</u>

摘要

旅行商问题是组合优化领域中最具代表性的路径规划问题之一，在交通运输、物流调度、芯片制造、仓储拣选和生物信息学等场景中具有广泛应用。传统精确算法在大规模实例上通常面临指数级搜索开销，启发式算法虽然能够得到较高质量的近似解，但往往依赖人工设计的局部搜索算子和较长的迭代时间。近年来，深度强化学习方法因具有端到端建模和快速推理的优势，被逐渐用于旅行商问题求解。然而，已有端到端模型在节点规模增大时容易受到显存占用和解码复杂度的限制，通常难以从小规模实例稳定泛化到更大规模问题。

本文围绕文献^[1]提出的 Pointerformer 方法，对面向旅行商问题的深度强化多指针 Transformer 框架进行整理、分析与学位论文格式化改写。该方法在编码端引入可逆残差网络以降低反向传播过程中的激活存储开销，在解码端采用多指针网络替代更重的自注意力交互，并结合特征增强与增强上下文嵌入，使模型同时利用节点坐标、图级表示、起点、当前节点以及已访问路径信息。训练方面，Pointerformer 基于改进的 REINFORCE 策略梯度算法，通过多起点采样和实例内归一化降低回报方差。实验结果表明，该方法在随机生成数据和 TSPLIB 实例上取得了较好的效率与解质量折中，并能够扩展到 500 节点旅行商实例。

本文的主要工作包括：首先，梳理旅行商问题、深度强化学习求解范式以及 Transformer 结构在组合优化中的应用背景；其次，系统阐述 Pointerformer 的问题建模、编码器、解码器、训练目标和推理流程；再次，依据原论文实验数据整理不同规模随机实例、公开基准实例及消融实验结果；最后，总结该方法在可扩展性、泛化能力和资源消耗方面的优势与局限，并讨论其向车辆路径规划等更复杂组合优化问题扩展的可能方向。

关键词：旅行商问题，深度强化学习，Transformer，多指针网络，组合优化

Abstract

The Traveling Salesman Problem (TSP) is a representative combinatorial optimization problem with broad applications in transportation, logistics, manufacturing, warehouse order picking, and bioinformatics. Exact solvers usually suffer from rapidly increasing computational cost on large-scale instances, while heuristic methods often depend on carefully designed search operators and long iterative procedures. Deep reinforcement learning has recently become a promising direction for solving TSP in an end-to-end manner because of its fast inference. Nevertheless, many existing end-to-end models are limited by memory consumption and decoding complexity, and therefore generalize poorly from small instances to large ones.

This thesis-style manuscript studies and reformats the Pointerformer method proposed in^[1]. Pointerformer is a deep reinforced multi-pointer Transformer for TSP. It employs reversible residual layers in the encoder to reduce activation memory during back-propagation, and uses a multi-pointer decoder to avoid heavy self-attention in the auto-regressive decoding stage. In addition, feature augmentation and enhanced context embedding are introduced so that the model can exploit node coordinates, graph-level information, depot information, current node information, and partial-route information. During training, a modified REINFORCE algorithm with multiple starting nodes and instance-wise normalization is used to reduce the variance of policy gradients. Experimental results show that Pointerformer achieves a competitive trade-off between solution quality and efficiency on random TSP instances and TSPLIB benchmarks, and can scale to TSP instances with up to 500 nodes.

The manuscript first reviews the background of TSP, deep reinforcement learning, and Transformer-based neural combinatorial optimization. It then presents the problem formulation, encoder design, decoder design, training objective, and inference procedure of Pointerformer. After that, experimental results and ablation studies are summarized according to the original paper. Finally, the advantages, limitations, and future extensions of Pointerformer are discussed.

Key Words: Traveling Salesman Problem, Deep Reinforcement Learning, Transformer, Multi-Pointer Network, Combinatorial Optimization

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 本文主要内容	2
1.4 论文组织结构	2
第二章 相关背景知识介绍	4
2.1 旅行商问题建模	4
2.2 强化学习求解范式	4
2.3 Transformer 与注意力机制	5
2.4 可逆残差网络	5
2.5 本章小结	6
第三章 Pointerformer 模型设计	7
3.1 整体架构	7
3.2 节点特征增强	7
3.3 可逆残差编码器	8
3.4 增强上下文嵌入	8
3.5 多指针解码器	9
3.6 本章小结	9
第四章 训练与推理方法	10
4.1 策略学习目标	10
4.2 多起点采样与共享基线	10
4.3 训练流程	11
4.4 推理流程	11
4.5 复杂度与资源分析	11
4.6 本章小结	12
第五章 实验结果与分析	13
5.1 实验数据集	13
5.2 对比方法与实验设置	13
5.3 随机实例实验结果	13
5.4 TSPLIB 泛化实验	14
5.5 消融实验分析	14
5.6 实验结论	15
5.7 本章小结	15
第六章 总结与展望	16
6.1 全文总结	16
6.2 不足之处	16
6.3 未来工作展望	17

参考文献 18

程序清单 20

攻读专业学位硕士期间撰写的论文..... 21

攻读专业学位硕士期间申请的专利..... 22

攻读专业学位硕士期间参加的科研项目..... 23

致谢 24

插图索引

图 3.1 Pointerformer 整体流程示意图.....7

表格索引

表 5.1	TSP random 数据集结果整理	14
表 5.2	TSPLIB 数据集结果整理	14
表 5.3	Pointerformer 关键模块消融实验	15

第一章 绪论

1.1 研究背景与意义

旅行商问题（Traveling Salesman Problem, TSP）是组合优化中的经典问题。给定若干城市及任意两城市之间的距离，旅行商需要从某一城市出发，恰好访问每个城市一次后回到起点，目标是在所有可行闭环路径中找到总距离最短的路径。TSP 形式简洁，但具有 NP-hard 特性，是检验优化算法建模能力、搜索能力和泛化能力的重要基准问题。

TSP 的应用场景十分广泛。在制造领域，印刷电路板钻孔顺序规划可抽象为带有序列相关代价的 TSP^[2]；在生物信息学和晶体学中，大规模点集扫描路径同样会导出旅行商问题^[3]；在物流调度、仓储拣选和运输路径优化中，TSP 及其扩展形式经常被用作车辆路径规划、订单分拣和即时配送的基础模型^[4-6]。因此，研究高效、可扩展并具有泛化能力的 TSP 求解方法具有重要理论价值和工程意义。

传统 TSP 求解方法大体包括精确算法、近似算法和启发式算法。Concorde 等精确求解器能够在许多标准实例上获得最优解^[7]，但在大规模问题上通常需要较高计算代价。Christofides 算法给出了具有理论近似保证的解法^[8]，但实际解质量和工程适应性仍受问题结构影响。LKH 系列启发式算法在实践中表现突出^[9]，但其性能依赖搜索策略、候选边构造和局部算子设计。面对在线调度、即时路径生成等时延敏感任务，仅依靠迭代式搜索可能难以满足实时性要求。

近年来，深度学习与强化学习为组合优化问题提供了新的研究路径。Pointer Network 首次展示了序列到序列神经网络处理可变长度组合结构的可能性^[10]，随后研究者将强化学习用于训练路径构造策略^[11]，并使用 Transformer 注意力结构进一步提升 TSP 求解能力^[12]。这类端到端方法在推理阶段通常只需一次或少量前向传播即可构造解，因此具有较高效率。但现有端到端模型在节点规模较大时常面临显存占用、训练方差和泛化能力不足等问题。

Pointerformer 是文献^[1]提出的一种面向 TSP 的深度强化多指针 Transformer 方法。它通过可逆残差编码器降低训练显存需求，通过多指针解码器提高自回归解码效率，并利用特征增强和增强上下文嵌入提升解质量与泛化能力。围绕该方法展开系统梳理，有助于理解深度强化学习求解大规模组合优化问题的关键设计思路。

1.2 国内外研究现状

早期机器学习求解 TSP 的尝试包括 Hopfield 神经网络^[13]和自组织特征映射^[14]。这些方法证明了神经计算可以表达优化偏好，但受限于模型容量、训练稳定性和解质量。随后，强化学习被用于改进蚁群算法、遗传算法和局部搜索策略，例如 Ant-Q^[15]、Q-ACS^[16] 以及结合

强化学习的 EAX-GA^[17]。这类方法通常仍依赖传统启发式框架，学习模块更多承担参数调节或算子选择功能。

深度学习方法大致可分为端到端构造式方法和搜索增强式方法。端到端方法直接根据节点集合逐步生成路径，代表性工作包括 Pointer Network^[10]、神经组合优化^[11]、Structure2Vec^[18]、Attention Model^[12] 和 POMO^[19]。这类方法推理速度快、对人工算子依赖少，但多数工作主要在 100 个节点以内的实例上验证。

搜索增强式方法通常先得到初始解或热力图，再结合 2-opt、动态规划、束搜索或蒙特卡洛树搜索进行改进。例如 DRL+2opt 通过强化学习指导 2-opt 局部搜索^[20]，Att-GCN+MCTS 使用图卷积模型产生热力图并以 MCTS 搜索解空间^[21]。这些方法可处理更大规模实例，但搜索阶段耗时较长，且解质量与搜索预算、局部算子和工程实现高度相关。

Pointerformer 试图在端到端效率和大规模可扩展性之间取得平衡。与依赖复杂搜索组件的方法不同，它使用一个可训练的编码-解码网络直接生成可行路径；与传统 Transformer 解码器不同，它通过多指针交互和上下文增强减少了大规模实例上的显存压力。这一思路为端到端神经优化模型处理更大规模 TSP 提供了可借鉴范式。

1.3 本文主要内容

本文以 Pointerformer 方法为研究对象，对其模型结构、训练策略和实验表现进行学位论文格式化整理。主要内容如下：

- (1) 梳理 TSP 的数学定义、应用背景和主要求解路线，说明深度强化学习方法应用于组合优化问题的动机。
- (2) 分析 Transformer、可逆残差网络、多指针网络和策略梯度训练在 Pointerformer 中的作用。
- (3) 给出 Pointerformer 的问题建模、编码器设计、解码器设计、训练目标和推理流程。
- (4) 整理随机 TSP 数据集和 TSPLIB 数据集上的实验结果，比较 Pointerformer 与代表性基线方法在解质量、推理时间和可扩展性方面的差异。
- (5) 总结该方法的优势与局限，并讨论其向车辆路径规划和其他组合优化问题扩展的方向。

1.4 论文组织结构

全文共分为六章。第一章介绍研究背景、国内外研究现状以及本文内容安排。第二章给

出 TSP、强化学习和 Transformer 相关基础知识。第三章阐述 Pointerformer 的模型结构，包括

特征增强、可逆残差编码器、增强上下文嵌入和多指针解码器。第四章介绍训练与推理算法。第五章整理实验设置、对比结果和消融分析。第六章总结全文并展望后续研究方向。

第二章 相关背景知识介绍

2.1 旅行商问题建模

本文关注二维欧氏旅行商问题。设 $G(V, E)$ 为一个完全无向图，其中 $V = \{v_i \mid 1 \leq i \leq N\}$ 表示 N 个城市节点， $E = \{e_{ij} \mid 1 \leq i, j \leq N\}$ 表示所有可能边。节点 v_i 的坐标为 (x_i, y_i) ，从 v_i 到 v_j 的移动代价定义为两点间欧氏距离：

$$\text{cost}(i, j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (2.1)$$

一条可行路径 τ 是一个包含全部节点的访问序列，且每个节点仅访问一次。路径最终需要回到起始节点，因此路径总长度可表示为

$$L(\tau) = \text{cost}(\tau[N], \tau[1]) + \sum_{i=1}^{N-1} \text{cost}(\tau[i], \tau[i+1]). \quad (2.2)$$

TSP 的优化目标是寻找总长度最小的路径：

$$\tau^* = \arg \min_{\tau \in \Omega} L(\tau), \quad (2.3)$$

其中 Ω 表示所有可行访问序列组成的集合。

由于可行解数量随节点数呈阶乘增长，TSP 在大规模实例上难以通过枚举获得最优解。深度强化学习方法通常不直接搜索全体可行解，而是学习一个参数化策略 π_θ ，按照当前状态逐步选择下一个节点，最终构造完整路径。

2.2 强化学习求解范式

在构造式神经求解器中，TSP 可被视为马尔可夫决策过程。状态包含输入图、已访问节点集合和当前部分路径；动作是在尚未访问的节点中选择下一个节点；奖励通常与路径长度的负值相关。对于问题实例 s ，策略 π_θ 生成路径 τ 的概率可写为

$$p_\theta(\tau \mid s) = \prod_{i=1}^N \pi_\theta(\tau[i] \mid s, \tau[:i]). \quad (2.4)$$

若令回报 $R(\tau) = -L(\tau)$ ，则训练目标为最大化期望回报：

$$J(\theta | s) = \mathbb{E}_{\tau \sim p_{\theta}(\tau | s)} R(\tau). \quad (2.5)$$

策略梯度方法可直接对离散动作序列进行优化。根据策略梯度定理，目标函数梯度可表示为

$$\nabla_{\theta} J(\theta | s) = \mathbb{E}_{p_{\theta}(\tau | s)} [\nabla_{\theta} \log p_{\theta}(\tau | s) R(\tau)]. \quad (2.6)$$

实际训练中通常引入基线函数以降低方差。Pointerformer 进一步利用每个实例的多起点轨迹构造共享基线，并进行实例内归一化，以改善训练稳定性^[1]。

2.3 Transformer 与注意力机制

Transformer 通过注意力机制建模序列元素之间的依赖关系^[22]。对于查询矩阵 Q 、键矩阵 K 和值矩阵 V ，缩放点积注意力定义为

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V. \quad (2.7)$$

多头注意力将输入投影到多个子空间中分别计算注意力，再将结果拼接并映射回原空间。对于 TSP 节点集合，注意力机制能够捕获任意两个节点之间的相互关系，因此被广泛用于神经组合优化模型。

不过，标准 Transformer 的自注意力复杂度与节点数平方相关。当节点规模增大时，编码器激活存储和解码器重复交互都会带来较高资源开销。Pointerformer 的核心改进之一就是在保持注意力表达能力的同时，通过可逆残差网络和多指针解码器降低训练与推理成本。

2.4 可逆残差网络

普通残差网络在反向传播时需要保存每一层激活值，以便计算梯度。可逆残差网络利用特殊结构，使得上一层输入可以由下一层输出反推得到，从而减少激活存储需求^[23,24]。设一层输入被拆分为 (X_1, X_2) ，输出为 (Y_1, Y_2) ，可逆残差结构可写为

$$Y_1 = X_1 + \text{MHA}(X_2), \quad (2.8)$$

$$Y_2 = X_2 + \text{FF}(Y_1). \quad (2.9)$$

反向计算时可由输出恢复输入：

$$X_2 = Y_2 - FF(Y_1), \quad (2.10)$$

$$X_1 = Y_1 - MHA(X_2). \quad (2.11)$$

因此，模型不必为每一层完整保存中间激活。对于多层 Transformer 编码器，这种结构有助于降低大规模 TSP 实例训练时的显存压力。

2.5 本章小结

本章介绍了旅行商问题的数学建模、强化学习求解目标、Transformer 注意力机制以及可逆残差网络。上述内容构成了 Pointerformer 方法的理论基础：TSP 提供组合优化任务，策略梯度提供端到端训练机制，Transformer 负责节点关系建模，而可逆残差结构则缓解大规模实例上的内存瓶颈。

第三章 Pointerformer 模型设计

3.1 整体架构

Pointerformer 采用编码器-解码器架构解决 TSP。编码器输入节点特征并输出每个节点的嵌入表示；解码器根据当前部分路径构造上下文查询，在未访问节点中选择下一个节点，直至生成完整路径。与常规 Transformer 求解器相比，Pointerformer 的主要差异体现在三个方面：第一，编码端使用特征增强，使输入不仅包含坐标，还包含由旋转、翻转和几何关系得到的扩展特征；第二，编码器残差结构采用可逆设计，以降低训练时显存消耗；第三，解码端使用多指针网络 and 增强上下文嵌入，减少自回归解码阶段的注意力开销。




图 3.1 Pointerformer 整体流程示意图

如图3.1所示，Pointerformer 以节点集合为输入，经特征增强后进入编码器。编码器输出的节点嵌入既用于构建图级表示，也用于解码器与候选节点交互。解码器每一步都会屏蔽已经访问过的节点，保证生成路径满足 TSP 可行性约束。

3.2 节点特征增强

在二维欧氏 TSP 中，原始输入通常只有节点坐标 (x, y) 。然而 TSP 具有平移、旋转、翻转等几何对称性，等价变换后的实例应当对应相同最优路径长度。为了让模型更好利用这些结构，Pointerformer 在输入层引入特征增强。对于每个节点，除坐标外还可构造

$$\eta = \arctan \frac{y}{x} \quad (3.1)$$

并结合旋转、翻转等等价变换得到多组特征。原论文最终为每个节点构造 24 维输入特征^[1]。

特征增强的作用有两个方面。一方面，它将 TSP 的几何不变性显式注入模型，使模型不必完全依靠训练数据学习这些对称关系；另一方面，多视角特征可以提高节点表示的判别性，从而帮助解码器在候选节点之间做出更稳定的选择。

3.3 可逆残差编码器

编码器由多层注意力模块构成。每层包含多头自注意力子层和前馈网络子层，但残差连接采用可逆形式。设某层输入被分为 X_1 和 X_2 ，则该层输出可写为

$$Y_1 = X_1 + \text{MHA}(X_2), \quad (3.2)$$

$$Y_2 = X_2 + \text{FF}(Y_1). \quad (3.3)$$

由于 (X_1, X_2) 可以由 (Y_1, Y_2) 反推出，训练时不必为每一层保存所有激活。对于节点数较大的 TSP 实例，编码器的自注意力已经带来较高显存占用，可逆残差结构能够显著缓解这一问题。

编码器输出记为 $\{h_i^{enc}\}_{i=1}^N$ ，其中 h_i^{enc} 表示第 i 个节点的上下文相关嵌入。由于 TSP 本身不包含自然序列顺序，Pointerformer 不使用传统位置编码，而是让注意力层直接根据节点特征学习节点间关系。

3.4 增强上下文嵌入

在自回归解码阶段，模型需要根据当前部分路径判断下一步应访问哪个未访问节点。已有方法通常使用起点、当前节点或图级表示构造上下文。Pointerformer 进一步引入已访问路径的整体信息，使解码器能够区分具有相同起点和终点但历史访问节点不同的部分路径。

设当前部分路径为 τ ，长度为 t 。增强上下文嵌入由四类信息组成：起点嵌入 $h_{\tau[1]}$ 、当前节点嵌入 $h_{\tau[t]}$ 、图级嵌入 h_g 和部分路径嵌入 h_τ 。其中

$$h_g = \sum_{i=1}^N h_i^{enc}, \quad (3.4)$$

$$h_\tau = \sum_{i=1}^t h_{\tau[i]}^{enc}. \quad (3.5)$$

第 t 步的查询向量定义为

$$q_t = \frac{1}{N}(h_g + h_\tau) + h_{\tau[t-1]} + h_{\tau[1]}. \quad (3.6)$$

其中，图级嵌入描述整体实例结构，路径嵌入描述已访问节点集合，起点和当前节点则提供路径闭合与局部移动信息。这一设计使模型在决策时能够同时考虑全局结构和局部路径状态。

3.5 多指针解码器

解码器以增强上下文嵌入 q_t 为查询，与未访问节点的键向量进行交互。不同于单一指针机制，多指针网络使用 H 组线性投影分别计算查询与候选节点之间的匹配分数，并对多个指针头的结果求平均。对于候选节点 j ，多指针交互可写为

$$P_j = \frac{1}{H} \sum_{h=1}^H \frac{(q_t W_h)^T (k_j W_h)}{d_k}. \quad (3.7)$$

为了引导模型从较合理的初始策略开始学习，Pointerformer 将当前节点 i 到候选节点 j 的距离作为惩罚项加入得分：

$$score_{ij} = P_j - \text{cost}(i, j). \quad (3.8)$$

该项鼓励模型优先考虑距离较近的节点，但最终选择仍由神经网络输出的概率分布决定。

对已访问节点进行掩码后，节点 j 的 logits 可表示为

$$u_{ij} = \begin{cases} C \tanh(score_{ij}), & \text{节点 } j \text{ 未访问,} \\ -\infty, & \text{节点 } j \text{ 已访问.} \end{cases} \quad (3.9)$$

最终通过 softmax 得到下一节点概率：

$$p_{ij} = \frac{\exp(u_{ij})}{\sum_{k=1}^N \exp(u_{ik})}. \quad (3.10)$$

其中 C 控制 logits 的范围，也影响训练中的探索与利用平衡。

3.6 本章小结

本章介绍了 Pointerformer 的整体结构和核心模块。特征增强利用 TSP 的几何对称性提升输入表达，可逆残差编码器降低多层注意力网络的训练显存，多指针解码器通过多个投影头增强候选节点选择能力，增强上下文嵌入则使解码过程同时关注全局图结构和当前部分路径。这些设计共同支撑了 Pointerformer 在较大规模 TSP 实例上的端到端求解能力。

第四章 训练与推理方法

4.1 策略学习目标

Pointerformer 使用强化学习方式训练路径构造策略。对给定实例 s ，模型按照策略 π_{ϑ} 自回归生成路径 τ 。由于 TSP 目标是最小化路径长度，训练时可将回报定义为路径长度的负值：

$$R(\tau) = -L(\tau). \quad (4.1)$$

最大化期望回报等价于最小化期望路径长度。使用 REINFORCE 算法^[25] 估计梯度时，有

$$\nabla_{\vartheta} J(\vartheta) = \mathbb{E}_{\tau \sim p_{\vartheta}} [\nabla_{\vartheta} \log p_{\vartheta}(\tau | s)(R(\tau) - b(s))], \quad (4.2)$$

其中 $b(s)$ 为基线项，用于降低梯度估计方差。

4.2 多起点采样与共享基线

TSP 中任意一个节点都可以作为起点，且同一闭环路径可以由不同起点表示。Pointerformer 借鉴 POMO 的多起点思想^[19]，对每个含 N 个节点的实例，从 N 个不同起点分别采样可行路径。设第 i 个实例生成的 N 条路径为

$$\tau_i = \{\tau_i^1, \tau_i^2, \dots, \tau_i^N\}. \quad (4.3)$$

若一个批次包含 B 个实例，则可得到 $B \times N$ 条训练轨迹。这种方式能够充分利用 TSP 的最优解性质，并提供更稳定的实例内基线。

原论文进一步对同一实例内的回报进行均值和方差归一化。设

$$\mu(\tau_i) = \frac{1}{N} \sum_{j=1}^N R(\tau_i^j), \quad (4.4)$$

$$\sigma(\tau_i) = \frac{1}{N} \sum_{j=1}^N (R(\tau_i^j) - \mu(\tau_i))^2. \quad (4.5)$$

则梯度近似为

$$\nabla_{\vartheta} J(\vartheta) \approx \frac{1}{B \times N} \sum_{i=1}^B \sum_{j=1}^N \frac{(R(\tau_i^j) - \mu(\tau_i))}{\sigma(\tau_i)} \nabla_{\vartheta} \log p_{\vartheta}(\tau_i^j | s_i). \quad (4.6)$$

该归一化能够减小不同实例之间路径长度尺度差异造成的训练震荡，从而提高收敛稳定性。

4.3 训练流程

Pointerformer 的训练流程如算法1所示。每个训练轮次随机生成一批 TSP 实例，经特征增强后送入可逆残差编码器。解码阶段从不同起点采样路径，计算路径长度与回报，再使用实例内归一化后的策略梯度更新模型参数。

算法 1 Pointerformer 训练流程

输入: 训练实例分布 $\mathcal{D}$, 模型参数 ϑ , 批大小 B

输出: 训练后的策略网络 π_{ϑ}

```

1: repeat
2:   从  $\mathcal{D}$  中采样  $B$  个 TSP 实例;
3:   对每个实例执行节点特征增强;
4:   使用可逆残差 Transformer 编码器计算节点嵌入;
5:   for 每个实例  $s_i$  do
6:     以每个节点作为起点, 采样  $N$  条路径  $\{\tau_i^j\}_{j=1}^N$ ;
7:     计算每条路径长度  $L(\tau_i^j)$  和回报  $R(\tau_i^j)$ ;
8:     计算实例内均值  $\mu(\tau_i)$  和方差  $\sigma(\tau_i)$ ;
9:   end for
10:  根据式(4.6)估计梯度;
11:  使用 Adam 优化器更新参数  $\vartheta$ ;
12: until 达到最大训练轮次或验证性能收敛

```

4.4 推理流程

推理阶段不需要反向传播，模型按自回归方式生成路径。对于每一步，解码器计算未访问节点的选择概率，并根据贪心策略或采样策略选出下一个节点。实验中，Pointerformer 可从多个起点生成多条候选路径，再选取长度最短者作为最终结果。该策略增加了少量前向计算，但能利用 TSP 闭环路径的多起点等价性提升解质量。

与搜索增强式方法相比，Pointerformer 的推理过程不依赖 2-opt、MCTS 等额外搜索模块，因此计算流程更简单、并行化更直接。对于在线路径规划等需要快速响应的场景，这种端到端推理方式具有明显优势。

4.5 复杂度与资源分析

Pointerformer 的主要计算开销来自编码器的多头自注意力和解码器的节点交互。编码器注意力仍具有 $O(N^2)$ 复杂度，但可逆残差结构减少了训练阶段保存激活带来的显存占用。解码器每一步需要与未访问节点计算交互，整体为 $O(N^2)$ 级别；多指针网络通过较轻量的投影与平均交互替代更重的解码自注意力，使实际推理更高效。

需要注意的是，可逆残差网络降低的是训练显存，而不是完全消除大规模实例的计算复杂度。因此，当节点规模继续扩展到数千或数万时，仍需要结合稀疏注意力、分治策略或局部搜索后处理等技术进一步优化。

4.6 本章小结

本章介绍了 Pointerformer 的强化学习训练目标、多起点采样策略、实例内归一化梯度估计以及推理流程。改进的 REINFORCE 算法通过共享基线与归一化降低训练方差，多起点推理则利用 TSP 的结构等价性提升解质量。上述训练与推理设计使 Pointerformer 能够在保持端到端特性的同时兼顾效率和稳定性。

第五章 实验结果与分析

5.1 实验数据集

Pointerformer 的实验主要包含随机生成实例和公开基准实例两类^[1]。

- (1) **TSP random**: 在单位正方形 $[0, 1]^2$ 中均匀采样节点, 构造 $N = 20, 50, 100, 200, 500$ 五组随机 TSP 实例。对于 $N \leq 100$ 的实例, 每组包含 10000 个测试样本; 对于 $N \geq 200$ 的实例, 每组包含 128 个测试样本。
- (2) **TSPLIB**: TSPLIB 是经典 TSP 标准库^[26], 包含来自实际应用的多种节点分布。原论文选取不超过 1002 个节点的实例, 并按规模划分为 1–100、101–500 和 501–1002 三组。

5.2 对比方法与实验设置

实验对比的端到端深度学习方法包括 Attention Model (AM)^[12]、POMO^[19] 和 AM+LCP^[27]; 搜索增强式方法包括 DRL+2opt^[20] 和 Att-GCN+MCTS^[21]。最优解或参考最优值由 Concorde 等精确求解器获得, 记为 OPT。

Pointerformer 在 TSP random 上训练不同规模的模型, 分别记为 Model20、Model50、Model100、Model200 和 Model500。训练时使用 Adam 优化器, 学习率为 10^{-4} , 权重衰减为 10^{-6} ; 编码器层数为 6, 多指针网络中 $d_k = 128$ 、指针头数 $H = 8$ 。这些设置均依据原论文整理。

5.3 随机实例实验结果

表5.1整理了不同方法在 TSP random 上的结果。Gap 表示相对 OPT 的百分比差距, Time 表示测试耗时。可以看出, Pointerformer 在小规模实例上能够达到与 POMO 等端到端方法接近的解质量, 在 200 和 500 节点实例上仍能完成端到端推理, 而多数端到端基线因显存或复杂度限制无法继续扩展。

从表5.1可见, Pointerformer 在 TSP200 上优于 Att-GCN+MCTS 的 Gap, 同时保持较短推理时间; 在 TSP500 上虽然解质量略弱于 Att-GCN+MCTS, 但仍能在端到端框架下处理该规模实例。由于搜索增强式方法通常需要额外迭代或树搜索, Pointerformer 在实时推理方面更具优势。

表 5.1 TSP random 数据集结果整理

方法	TSP20		TSP50		TSP100		TSP200		TSP500	
	Len	Gap(%)	Len	Gap(%)	Len	Gap(%)	Len	Gap(%)	Len	Gap(%)
OPT	3.83	—	5.69	—	7.76	—	10.72	—	16.55	—
AM	3.83	0.06	5.72	0.49	7.94	23.20	—	—	—	—
POMO	3.83	0.00	5.69	0.02	7.77	0.16	—	—	—	—
AM+LCP	3.84	0.00	5.70	0.02	7.81	0.54	—	—	—	—
DRL+2opt	3.83	0.00	5.70	0.12	7.82	0.78	—	—	—	—
Att-GCN+MCTS	3.83	0.00	5.69	0.01	7.76	0.04	10.81	0.88	16.97	2.54
Pointerformer	3.83	0.00	5.69	0.02	7.77	0.16	10.79	0.68	17.14	3.56

5.4 TSPLIB 泛化实验

为了评估泛化能力，原论文将随机实例上训练得到的模型直接应用到TSPLIB实例。表5.2给出了整理结果。可以看出，POMO在100节点以内实例上表现较好，而Pointerformer在更大规模组别中具有更强泛化能力，尤其在501–1002节点实例上取得了更低的Gap。

表 5.2 TSPLIB 数据集结果整理

方法	TSPLIB1–100		TSPLIB101–500		TSPLIB501–1002	
	Len	Gap(%)	Len	Gap(%)	Len	Gap(%)
OPT	19454.17	—	40842.43	—	62427.71	—
AM	22283.67	15.36	72137.93	78.18	140664.29	139.02
POMO	19628.67	1.20	43652.77	6.99	82162.29	26.93
DRL+2opt	19916.50	2.43	46651.40	13.85	82797.71	42.57
Pointerformer(Model100)	19728.50	1.33	42963.20	5.43	75081.43	18.65
Pointerformer(Model200)	20135.00	2.91	43810.67	8.37	73915.57	18.20

TSPLIB实例与随机均匀分布实例存在明显分布差异。Pointerformer在未针对TSPLIB重新训练的情况下仍能获得较低Gap，说明增强上下文嵌入和可扩展训练规模有助于提升跨分布泛化能力。特别是Model200在大规模组别上优于Model100，表明训练规模越接近测试规模，模型对大规模结构的适应性越强。

5.5 消融实验分析

为了分析各模块贡献，原论文在TSP random200上比较了完整模型与三个变体：去除特征增强、去除增强上下文嵌入、去除多指针网络。结果如表5.3所示。

从表5.3可以看出，三个模块均对最终性能有正向作用。其中，去除增强上下文嵌入后Gap上升最明显，说明仅依靠起点和当前节点不足以完整表达部分路径状态；路径嵌入能够为后续节点选择提供重要历史信息。特征增强带来的提升相对温和，但有助于模型利用TSP的几何对称性。多指针网络对随机实例的数值提升较小，但结合泛化实验可知，它对不同分布实

表 5.3 Pointerformer 关键模块消融实验

算法	Len	Gap(%)
Pointerformer	10.793	0.68
去除特征增强	10.813	0.87
去除增强上下文嵌入	11.013	2.73
去除多指针网络	10.797	0.72

例上的鲁棒性仍具有价值。

5.6 实验结论

综合随机实例、TSPLIB 实例和消融实验，可以得到以下结论：

- (1) Pointerformer 在小规模 TSP 上能够达到与现有端到端模型相近的解质量，在 200 和 500 节点实例上具备更好的可扩展性。
- (2) 与搜索增强式方法相比，Pointerformer 在推理流程上更简洁，能够以更短时间生成质量较高的路径。
- (3) 增强上下文嵌入对性能影响最显著，说明当前部分路径信息是自回归 TSP 解码中的关键因素。
- (4) 在 TSPLIB 上的结果表明，较大规模训练和结构化上下文设计有助于提升模型跨分布泛化能力。

5.7 本章小结

本章整理并分析了 Pointerformer 在随机 TSP 和 TSPLIB 数据集上的实验结果。实验表明，该方法在解质量、推理效率和可扩展性之间取得了较好平衡。消融实验进一步说明，特征增强、增强上下文嵌入和多指针网络共同构成了 Pointerformer 性能提升的关键来源。

第六章 总结与展望

6.1 全文总结

本文围绕面向旅行商问题的深度强化多指针 Transformer 方法 Pointerformer 展开整理与分析。TSP 是组合优化领域的经典问题，具有重要理论意义和广泛应用价值。传统精确算法在大规模实例上计算代价较高，启发式算法虽具备较强实用性，但依赖人工设计的搜索算子和迭代过程。深度强化学习端到端方法能够快速构造解，但在大规模节点场景下容易受到显存和解码复杂度限制。

Pointerformer 通过多个结构设计缓解上述问题。首先，特征增强机制显式利用 TSP 的几何对称性，使节点输入表示更加充分。其次，可逆残差 Transformer 编码器减少反向传播过程中的激活存储，提升了大规模实例训练的可行性。再次，增强上下文嵌入同时整合图级信息、起点信息、当前节点信息和已访问路径信息，使自回归解码器能够基于更完整的状态进行决策。最后，多指针网络以轻量方式增强查询与候选节点之间的交互，并结合距离惩罚引导模型学习更有效的路径构造策略。

实验结果表明，Pointerformer 在随机生成的 TSP 实例上能够取得与代表性深度强化学习方法相近的解质量，并扩展到 500 个节点规模；在 TSPLIB 公共基准上，模型表现出较好的跨分布泛化能力。消融实验说明，增强上下文嵌入、特征增强和多指针网络均对模型性能有积极影响。

6.2 不足之处

尽管 Pointerformer 在端到端 TSP 求解中具有较好表现，但仍存在一些不足。

- (1) 编码器自注意力仍具有平方级复杂度。当节点规模进一步扩展到数千或更大时，仅依靠可逆残差结构难以完全解决计算瓶颈。
- (2) 模型主要面向二维欧氏 TSP，对带时间窗、容量约束、动态订单等现实约束的路径规划问题还需要额外建模。
- (3) 强化学习训练仍可能受到采样效率和方差影响，训练成本较高，对超参数和实例分布存在一定敏感性。
- (4) 与强启发式算法相比，端到端模型在最优性保证方面仍然不足，实际应用中可能需要结合搜索后处理或约束修复机制。

6.3 未来工作展望

未来研究可以从以下几个方向展开：

- (1) **更大规模的高效注意力结构**。可探索稀疏注意力、局部注意力、分块编码或图采样机制，以降低节点数增长带来的计算开销。
- (2) **与启发式搜索结合**。可在 Pointerformer 生成初始解后使用 2-opt、LKH 或轻量局部搜索进行后处理，从而在保持推理效率的同时进一步提升解质量。
- (3) **面向复杂路径规划问题扩展**。将模型迁移到车辆路径问题、带时间窗车辆路径问题、多车辆协同调度等任务，需要在状态表示、动作约束和奖励设计上进行扩展。
- (4) **提升跨分布泛化能力**。可结合分布鲁棒优化、元学习或多分布训练，使模型在不同城市分布、不同规模和不同约束条件下保持稳定性能。
- (5) **增强可解释性**。通过分析注意力权重、指针头分工和路径嵌入演化过程，可以更好理解神经组合优化模型的决策机制。

总体而言，Pointerformer 展示了端到端深度强化学习方法求解较大规模 TSP 的潜力。围绕其结构进一步改进，有望推动神经组合优化方法在实际路径规划与智能调度系统中的应用。

参考文献

- [1] Jin Y, Ding Y, Pan X, et al. Pointerformer: Deep Reinforced Multi-Pointer Transformer for the Traveling Salesman Problem[C]. Proceedings of the AAAI Conference on Artificial Intelligence. [S.l.: s.n.], 2023: 8132–8140.
- [2] Alkaya A F, Duman E. Application of Sequence-Dependent Traveling Salesman Problem in Printed Circuit Board Assembly[J]. IEEE Transactions on Components, Packaging and Manufacturing Technology, 2013, 3(6): 1063–1076.
- [3] Bland R G, Shallcross D F. Large Travelling Salesman Problems Arising from Experiments in X-Ray Crystallography: A Preliminary Report on Computation[J]. Operations Research Letters, 1989, 8(3): 125–128.
- [4] Madani A, Batta R, Karwan M. The Balancing Traveling Salesman Problem: Application to Warehouse Order Picking[J]. TOP, 2020.
- [5] Hacizade U, Kaya I. GA Based Traveling Salesman Problem Solution and Its Application to Transport Routes Optimization[J]. IFAC-PapersOnLine, 2018, 51(30): 620–625.
- [6] Matai R, Singh S, Lal M. Traveling Salesman Problem: An Overview of Applications, Formulations, and Solution Approaches[M]. Traveling Salesman Problem, Theory and Applications. [S.l.: s.n.], 2010.
- [7] Applegate D L, Bixby R E, Chvatal V, et al. The Traveling Salesman Problem: A Computational Study[M]. [S.l.]: Princeton University Press, 2007.
- [8] Christofides N. Worst-Case Analysis of a New Heuristic for the Travelling Salesman Problem[R]. [S.l.]: Carnegie-Mellon University, 1976.
- [9] Helsgaun K. An Extension of the Lin-Kernighan-Helsgaun TSP Solver for Constrained Traveling Salesman and Vehicle Routing Problems[R]. [S.l.]: Roskilde University, 2017.
- [10] Vinyals O, Fortunato M, Jaitly N. Pointer Networks[C]. Advances in Neural Information Processing Systems: volume 28. [S.l.: s.n.], 2015.
- [11] Bello I, Pham H, Le Q V, et al. Neural Combinatorial Optimization with Reinforcement Learning[M]. [S.l.: s.n.], 2016.
- [12] Kool W, van Hoof H, Welling M. Attention, Learn to Solve Routing Problems![C]. International Conference on Learning Representations. [S.l.: s.n.], 2018.
- [13] Hopfield J J, Tank D W. Neural Computation of Decisions in Optimization Problems[J]. Biological Cybernetics, 1985, 52(3): 141–152.
- [14] Angeniol B, Vaubois G d l C, Le Texier J Y. Self-Organizing Feature Maps and the Travelling Salesman Problem [J]. Neural Networks, 1988, 1(4): 289–293.
- [15] Gambardella L M, Dorigo M. Ant-Q: A Reinforcement Learning Approach to the Traveling Salesman Problem [M]. Machine Learning Proceedings 1995. [S.l.]: Elsevier, 1995: 252–260.
- [16] Sun R, Tatsumi S, Zhao G. Multiagent Reinforcement Learning Method with an Improved Ant Colony System [C]. 2001 IEEE International Conference on Systems, Man and Cybernetics: volume 3. [S.l.: s.n.], 2001: 1612–

1617.

- [17] Liu F, Zeng G. Study of Genetic Algorithm with Reinforcement Learning to Solve the TSP[J]. Expert Systems with Applications, 2009, 36(3): 6995–7001.
- [18] Dai H, Khalil E B, Zhang Y, et al. Learning Combinatorial Optimization Algorithms over Graphs[C]. Advances in Neural Information Processing Systems: volume 30. [S.l.: s.n.], 2017: 6348–6358.
- [19] Kwon Y D, Choo J, Kim B, et al. POMO: Policy Optimization with Multiple Optima for Reinforcement Learning [C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2020.
- [20] d O Costa P R, Rhuggenaath J, Zhang Y, et al. Learning 2-Opt Heuristics for the Traveling Salesman Problem via Deep Reinforcement Learning[C]. Asian Conference on Machine Learning. [S.l.: s.n.], 2020: 465–480.
- [21] Fu Z H, Qiu K B, Zha H. Generalize a Small Pre-Trained Model to Arbitrarily Large TSP Instances[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 35. [S.l.: s.n.], 2021: 7474–7482.
- [22] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2017: 5998–6008.
- [23] Gomez A N, Ren M, Urtasun R, et al. The Reversible Residual Network: Backpropagation without Storing Activations[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2017: 2211–2221.
- [24] Kitaev N, Kaiser L, Levskaya A. Reformer: The Efficient Transformer[C]. International Conference on Learning Representations. [S.l.: s.n.], 2019.
- [25] Williams R J. Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning [M]. Reinforcement Learning. [S.l.]: Springer, 1992: 5–32.
- [26] Reinelt G. TSPLIB—A Traveling Salesman Problem Library[J]. ORSA Journal on Computing, 1991, 3(4): 376–384.
- [27] Kim M, Park J. Learning Collaborative Policies to Solve NP-Hard Routing Problems[C]. Advances in Neural Information Processing Systems: volume 34. [S.l.: s.n.], 2021.

程序清单

本文主要依据文献^[1]对 Pointerformer 方法进行结构化整理，未在本模板中附完整工程代码。为便于后续复现，算法2给出推理阶段的核心伪代码。

算法 2 Pointerformer 推理流程

输入: TSP 实例 s , 训练后的策略网络 π_θ

输出: 近似最优路径 τ

```

1: 对输入节点执行特征增强;
2: 使用编码器计算节点嵌入  $\{h_i^{enc}\}_{i=1}^N$ ;
3: for 每个候选起点 do
4:   初始化部分路径并标记已访问节点;
5:   while 仍存在未访问节点 do
6:     根据当前部分路径计算上下文查询  $q_t$ ;
7:     使用多指针网络计算未访问节点概率;
8:     选择概率最大的节点并加入路径;
9:   end while
10:  计算闭环路径长度;
11: end for
12: 返回长度最短的候选路径;
```

攻读专业学位硕士期间撰写的论文

请在此处填写攻读专业学位硕士期间已发表、录用或投稿的论文信息。若无相关成果，可按学院要求保留“无”或删除本附录。

1. 无。

攻读专业学位硕士期间申请的专利

请在此处填写攻读专业学位硕士期间申请或授权的专利信息。若无相关成果，可按学院要求保留“无”或删除本附录。

1. 无。

攻读专业学位硕士期间参加的科研项目

请在此处填写攻读专业学位硕士期间参与的科研项目、工程项目或实践项目。若无相关项目，可按学院要求保留“无”或删除本附录。

1. 无。

致谢

请在此处填写致谢内容。通常可感谢导师、课题组成员、同学、家人以及在论文写作和实验复现过程中提供帮助的人员。